

La reproductibilité au service de la recherche et de la mise en production de projets statistiques

Romain Avouac

Insee, Direction des statistiques
démographiques et sociales

Lino Galiana 

Insee, Direction des statistiques
démographiques et sociales


26 novembre 2025

Insee 
Mesurer pour comprendre

Contexte

- “**Crise de la reproductibilité**” durable dans la recherche
 - Ioannidis (2005), Chang et Li (2017), Kapoor et Narayanan (2023)...
 - Enjeu similaire dans l’industrie avec le problème du mur de la production (Davenport et Malone 2021)
- Facteurs multiples:
 - Acculturation et incitations limités aux enjeux de reproductibilité ;
 - Auditabilité limitée avec des données non partageables ;
 - Recours à des logiciels propriétaires difficiles à auditer...
- Mouvement de la **science ouverte** et **politique plus active des revues scientifiques** pour plus de transparence


Exemple: la politique de l'AEA



Frise empruntée à Colliard, Hurlin, et Pérignon (2023)

Plus de détails récents, dans [AEA Data and code sharing policy](#)  et Vilhuber et Cavanagh (2025)

L'échelle de la reproductibilité



Source: Peng (2011)


- Une reproductibilité parfaite est coûteuse
- **Git** est un standard atteignable et efficient

Partage et transparence des données


- Beaucoup de **données non partageables** (secret industriel, confidentialité...)
 - France : accès simplifié aux données pour les chercheurs avec le CASD
- Approches à plusieurs niveaux :
 - Partage du protocole de collecte (sciences expérimentales)
 - Données synthétiques
 - Tiers de confiance (**Pérignon et al. 2019**)
- Sujet de **bonnes pratiques** dans le format des données sources et intermédiaires
 - ~~Excel~~ ● , CSV ● , Parquet ●
- Si la réplique n'est pas toujours possible, on peut au moins **viser la reproductibilité**

Le début des problèmes

Projet désordonné



Le premier pas



Partage et transparence du code

Premier niveau: lisibilité du code

“Le code est plus souvent lu qu’utilisé”. Guido Van Rossum

- Un **outil de communication** de la méthodologie
 - et de réplication de celle-ci (ex : *package*  d'économétrie)
- **Conventions communautaires** : *tidyverse style guide* () , *PEP8* et *PEP257* ()
- **Outils simples** pour mettre en oeuvre : les *formatters*
 - Très communs en . Le meilleur : **ruff**
 - Moins utilisés en  mais utiles. Le nouveau venu : **Air**

Partage et transparence du code

Deuxième niveau: lisibilité de la structure

Plus de détails dans le cours de mise en production de l'ENSAE ([Avouac et Galiana 2025](#))

- report.ipynb
- correlation.png
- data.csv
- data2.csv
- fig1.png
- figure 2 (copy).png
- report.pdf
- partial data.csv
- script.py
- script_final.py

- data
 - raw
 - dpe_logement_202103.csv
 - dpe_logement_202003.csv
 - interim
 - dpe_logement_merged_preprocessed.csv
- notebooks
 - report.ipynb
- src
 - main.R
 - preprocessing.R
 - generate_plots.R
- reports
 - report.pdf
 - figures
 - histogram_energy_diagnostic.png
 - barplot_consumption_pcs.png
 - correlation_matrix.png
 - correlation.png


Partage et transparence du code

Troisième niveau: d'où vient ce chiffre ?

- **Git** , la première des bonnes pratiques
 - Fiabilise le partage et l'évolution du code
 - Oblige à se poser la question des bonnes pratiques
 - Ne suffit pas lorsqu'on a plus du code dans un projet
- **“Literate programming”** (Knuth 1984) = mélanger texte et code:
 - Jongler entre le code et le papier dans *L^AT_EX*: source d'erreur
 - **Jupyter notebook** : intéressant (Perkel 2018) mais potentiels problèmes de reproductibilité (Samuel et Mietchen 2023).
 - Meilleur outil : **Quarto** !

Partage et transparence de la configuration

Un projet lisible, structuré et versionné suffit-il à assurer la reproductibilité ?



It works on my machine

Partage et transparence de la configuration

- De nombreux **éléments d'environnement** peuvent faire qu'un code est non répliquable:
 - Environnement logiciel, secrets d'authentification, etc.
 - Certains sont partageables, d'autres non (ex: jetons d'API )
 - (Auto)documenter dans le code (variables d'environnement et **dotenv** ou **.Renviron**)
- Solution 1 : **environnements virtuels**
 - Partager la recette de construction de l'environnement ayant permis de faire tourner le code
 - Solution technique: **venv** ou **uv** () , **renv** en ()
- Solution 2: la **conteneurisation**
 - Partager la recette de construction de l'ordinateur ayant permis de faire tourner le code
 - Solution technique: **Docker** 

Conclusion

- On a des **outils techniques** à utiliser pour résoudre la crise de la reproductibilité:
 - Socle minimal est atteignable simplement,
 - Etapes suivantes selon les projets.
- Mais aussi et surtout une **démarche à adopter**
- Aux **bénéfices nombreux**:
 - Moindre coût de maintenance,
 - Plus de transparence, de réutilisation...

Références

- Avouac, Romain, et Lino Galiana. 2025. « Mise en production de projets data science ». Cours à l'ENSAE. <https://doi.org/10.5281/zenodo.17486259>.
- Chang, Andrew C., et Phillip Li. 2017. « A Preanalysis Plan to Replicate Sixty Economics Research Papers That Worked Half of the Time ». *American Economic Review* 107 (5): 60-64. <https://doi.org/10.1257/aer.p20171034>.
- Colliard, Jean-Edouard, Christophe Hurlin, et Christophe Pérignon. 2023. « The economics of computational reproducibility ». *HEC Paris Research Paper No. FIN-2019-1345*.
- Davenport, Thomas, et Katie Malone. 2021. « Deployment as a Critical Business Data Science Discipline ». *Harvard Data Science Review* 3 (1).
- Ioannidis, John PA. 2005. « Why most published research findings are false ». *PLoS medicine* 2 (8): e124.
- Kapoor, Sayash, et Arvind Narayanan. 2023. « Leakage and the reproducibility crisis in machine-learning-based science ». *Patterns* 4 (9).
- Knuth, D. E. 1984. « Literate Programming ». *The Computer Journal* 27 (2): 97-111. <https://doi.org/10.1093/comjnl/27.2.97>.

- Peng, Roger D. 2011. « Reproducible research in computational science ». *Science* 334 (6060): 1226-27.
- Pérignon, Christophe, Kamel Gadouche, Christophe Hurlin, Roxane Silberman, et Eric Debonnel. 2019. « Certify reproducibility with confidential data ». *Science* 365 (6449): 127-28.
- Perkel, Jeffrey M. 2018. « Why Jupyter is data scientists' computational notebook of choice ». *Nature* 563 (7732): 145-47.
- Samuel, Sheeba, et Daniel Mietchen. 2023. « Computational reproducibility of Jupyter notebooks from biomedical publications ». <https://arxiv.org/abs/2308.07333>.
- Vilhuber, Lars, et Jack Cavanagh. 2025. « Report of the AEA Data Editor ». *AEA Papers and Proceedings* 115 (mai): 944-57. <https://doi.org/10.1257/pandp.115.944>.